



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ  
ФЕДЕРАЦИИ  
**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ  
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ  
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»  
(ДГТУ)**

Подразделение, ответственное за реализацию дополнительной профессиональной программы профессиональной переподготовки «Искусственный интеллект и машинное обучение» (далее-ДПП ПП) - Центр «Цифровая культура»

Руководитель ДПП ПП – к.т.н., доцент, зав. каф. «Програмное обеспечение вычислительной техники и автоматизированных систем» В.В. Долгов

## ОТЧЕТ

По практической подготовке при проведении практики в ООО «Дельта-Дон»

Обучающийся  13.05.2023  
подпись, дата

Отрешко Д.А.  
И.О.Ф.

Группа МКИС22

Программа профессиональной переподготовки: «Искусственный интеллект и машинное обучение» (256ч.)

Руководитель  
практической  
подготовки от ДГТУ

Преподаватель  
должность

Филиппенко В.А.  
И. О. Ф.

Оценка Отлично

13.05.2023  
дата

  
подпись руководителя от ДГТУ

Ростов-на-Дону

2023 г.



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ  
РОССИЙСКОЙ ФЕДЕРАЦИИ

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ  
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ  
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»  
(ДГТУ)**

Подразделение, ответственное за реализацию ДПП ПП «Искусственный интеллект и машинное обучение» - Центр «Цифровая культура»

**ЗАДАНИЕ**

По практической подготовке при проведении практики в ООО «Дельта-Дон»

в период с «17» апреля 2023 г. по «13» мая 2023 г.

Обучающийся Отрешко Даниил Артемович

Группа МКИС22

Срок представления отчета в ДГТУ «13» мая 2023 г.

Содержание индивидуального задания:

Разработать модель для определения патологических элементов почек на основе анализа КТ снимков технологиями искусственного интеллекта

Руководитель  
практической  
подготовки от ДГТУ

17.04.2023  
подпись, дата

Преподаватель  
Виктор  
Александрович  
Филиппенко  
должность, И.О.Ф.

Задание принял к  
исполнению

17.04.2023  
подпись, дата

Отрешко  
Даниил  
Артемович

## ДНЕВНИК ПРОХОЖДЕНИЯ ПРАКТИЧЕСКОЙ ПОДГОТОВКИ

Дата	Место работы/практики	Выполняемые работы
17.04.2023	ООО «Дельта-Дон»	Знакомство с предприятием, прохождение вводного инструктажа.
17.04.2023	ООО «Дельта-Дон»	Ознакомление с территорией предприятия, прохождение первичного инструктажа по ТБ, ПБ
18.04.2023	ООО «Дельта-Дон»	Получение индивидуального задания
19.04.2023 – 22.04.2023	ООО «Дельта-Дон»	Аналитический обзор предметной области, постановка задачи
24.04.2023 – 30.04.2023	ООО «Дельта-Дон»	Формирование датасета, выбор модели и определение ее архитектуры
2.05.2023 – 8.05.2023	ООО «Дельта-Дон»	Программная реализация
10.05.2023	ООО «Дельта-Дон»	Тестирование модели
11.05.2023-12.05.2023	ООО «Дельта-Дон»	Подготовка и оформление отчета по практике
13.05.2023	ООО «Дельта-Дон»	Сдача итогового отчета

## ОТЗЫВ - ХАРАКТЕРИСТИКА

Обучающийся \_\_\_\_\_ Отрешко Даниил Артемович  
фамилия, имя, отчество

Второго \_\_\_\_ курса группы \_\_\_\_ МКИС22

Наименование места практической подготовки

\_\_\_\_ ООО «Дельта-Дон» \_\_\_\_\_

наименование предприятия

Обучающийся по программе дополнительного профессионального образования профессиональной переподготовки «Искусственный интеллект и машинное обучение» выполнил задания предусмотренные рабочей программы практической подготовки в полном объёме.

Дополнительно ознакомился/изучил

---

---

---

---

---

Заслуживает оценки \_\_\_\_\_

Отлично

Руководитель практической  
подготовки

Решеткин В.А.  
« 13 » май 2023 г.

# Содержание

Введение	3
1. Аналитический обзор предметной области	5
1.1 Обзор задачи классификации изображений	5
1.2 Обзор методов машинного обучения для классификации изображений	6
1.3 Постановка задачи	7
2. Описание модели классификации изображений	9
2.1 Обоснование выбора модели	9
2.2 Архитектура модели	10
2.3 Алгоритм применения модели для классификации изображений	11
3. Программная реализация модели	13
3.1 Обоснование выбора средств разработки	13
3.2 Описание программной реализации	14
4. Тестирование модели	16
4.1 Описание процесса тестирования	16
Заключение	18
Перечень использованных информационных ресурсов	19
Приложение А Листинг программы	20

## Введение

Задача распознавания изображений является очень важной, так как возможность автоматического распознавания компьютером изображений приносит множество новых возможностей в развитии науки и техники, таких, как разработка систем поиска лиц и других объектов на фотографиях, контроля качества производимой продукции без участия человека, автоматического управления транспортом и множество других.

В последние годы модели глубокого обучения, основанные на нейронных сетях, стали мощным инструментом в области медицинской диагностики, позволяя автоматизировать процесс анализа медицинских изображений и достичь высокой точности при распознавании патологий. Распознавание заболеваний почек имеет критическое значение для ранней диагностики, эффективного лечения и предотвращения прогрессирования патологий почечной системы.

Особое значение имеет распознавание изображений в медицинской сфере, где точность и скорость диагностики являются ключевыми факторами для успешного лечения пациентов.

Одной из распространенных медицинских процедур, которая предоставляет детальные изображения внутренних органов, является компьютерная томография (КТ). КТ снимки, включая снимки почек, предоставляют ценную информацию для диагностики различных заболеваний, таких как кисты, камни и опухоли. Однако, интерпретация и анализ большого объема КТ снимков требует значительных усилий и времени со стороны врачей.

Именно в этом контексте возникает важная задача распознавания и классификации заболеваний почек на основе КТ снимков. Автоматизация этого процесса с использованием искусственного интеллекта и глубокого обучения может значительно улучшить точность диагностики, сократить время анализа и повысить качество здравоохранения.

В работе будут рассмотрены основные принципы глубокого обучения, используемые для создания модели, включая сверточные нейронные сети. Будут проведены эксперименты на реальных данных, чтобы оценить производительность модели и ее способность корректно классифицировать различные заболевания почек.

Данную модель можно будет интегрировать в компьютерные томографы для быстрого получения результата обследования.

# **1. Аналитический обзор предметной области**

## **1.1 Обзор задачи классификации изображений**

Задача классификации изображений имеет важное значение в области компьютерного зрения и искусственного интеллекта. Она заключается в определении категории или класса, к которому принадлежит данное изображение. В контексте нашего проекта, мы сосредоточены на задаче классификации изображений, связанных с заболеваниями почек на основе КТ снимков.

Одной из сложностей при классификации изображений почек является наличие различных заболеваний, таких как кисты, камни и опухоли, которые могут иметь схожие визуальные признаки на КТ снимках. Это создает сложности в точной и надежной идентификации их типа и характеристик.

Для решения этой задачи, мы планируем использовать сверточные нейронные сети, которые являются мощным инструментом в области классификации изображений. Сверточные нейронные сети способны автоматически извлекать иерархические признаки из изображений, что позволяет им эффективно обрабатывать и классифицировать сложные структуры и объекты.

Наша цель заключается в обучении сверточной нейронной сети распознавать и классифицировать заболевания почек на КТ снимках. Для этого мы планируем создать подготовленный набор данных, который будет содержать размеченные изображения с указанием соответствующего класса. Затем мы обучим сверточную нейронную сеть на этом наборе данных, чтобы она научилась распознавать различные типы заболеваний.

После завершения работы модели, мы ожидаем получить результаты, которые покажут высокую точность и достоверность в классификации заболеваний почек на основе КТ снимков. Это позволит врачам более точно и



быстро определять наличие и тип заболевания, что в свою очередь поможет в принятии решений о лечении и планировании медицинских процедур.

Задача классификации изображений почек на КТ снимках является важным аспектом нашего проекта, поскольку она может значительно улучшить процесс диагностики заболеваний почек и повысить качество здравоохранения.

## **1.2 Обзор методов машинного обучения для классификации изображений**

Классификация изображений является одной из фундаментальных задач в области компьютерного зрения. Ее цель состоит в определении класса или категории, к которой принадлежит данное изображение. В последние годы развитие методов машинного обучения сделало возможным значительные успехи в этой области. Ниже представлен обзор некоторых методов машинного обучения, применяемых для классификации изображений:

1. Сверточные нейронные сети (CNN): CNN являются наиболее широко используемыми моделями для классификации изображений. Они успешно применяются благодаря своей способности автоматически извлекать признаки из изображений с помощью сверточных слоев и объединения (pooling). Примером популярной архитектуры CNN является VGGNet, ResNet и InceptionNet.

2. Метод опорных векторов (SVM): SVM — это классический метод машинного обучения, который может быть успешно применен для классификации изображений. SVM строит гиперплоскость, которая максимально разделяет изображения разных классов в многомерном пространстве признаков.

3. Деревья принятия решений (Decision Trees): Деревья принятия решений являются простым и интерпретируемым методом для классификации

изображений. Они создают древовидную структуру, в которой каждый узел представляет признак, а каждое ребро - возможное значение этого признака.

4. Случайный лес (Random Forest): Random Forest — это ансамблевый метод, который комбинирует несколько деревьев принятия решений для получения более точной классификации изображений. Он использует случайные подвыборки данных и случайные подвыборки признаков для каждого дерева, чтобы уменьшить переобучение и повысить обобщающую способность модели.

5. Глубокое обучение (Deep Learning): Глубокое обучение — это подраздел машинного обучения, основанный на использовании глубоких нейронных сетей. Он предлагает мощные модели, способные автоматически изучать признаки из больших объемов данных. Глубокие нейронные сети, такие

### **1.3 Постановка задачи**

Целью проекта является разработка модели машинного обучения для автоматического распознавания и классификации заболеваний почек на основе КТ снимков. Задача заключается в создании эффективной и точной модели, способной определять наличие и типы заболеваний, таких как кисты, камни и опухоли, на КТ снимках.

Для достижения этой цели мы ставим перед собой следующие задачи:

1. Сбор и подготовка данных: мы будем собирать и создавать набор данных, состоящий из КТ снимков почек с различными заболеваниями. Эти данные будут размечены и классифицированы соответствующим образом, чтобы обеспечить основу для обучения модели.
2. Разработка модели классификации: мы будем исследовать и выбирать подходящие модели машинного обучения, способные эффективно классифицировать изображения почек на основе их визуальных признаков.
3. Обучение и настройка модели: мы будем обучать выбранную модель на нашем подготовленном наборе данных. Это включает в себя подгонку

параметров модели, выбор оптимальных гиперпараметров и применение методов регуляризации для предотвращения переобучения.

4. Оценка и валидация модели: мы будем оценивать производительность модели с помощью метрик, таких как точность, полнота и F1-мера. Мы также проведем валидацию модели на отдельном тестовом наборе данных, чтобы проверить ее обобщающую способность и надежность.

5. Развертывание и применение модели: после успешного обучения и валидации модели, мы планируем интегрировать ее в систему для реального применения. Это позволит врачам и медицинскому персоналу быстро и точно определять заболевания почек на основе КТ снимков, что в свою очередь поможет в принятии решений о лечении и улучшит качество здравоохранения.

## **2. Описание модели классификации изображений**

### **2.1 Обоснование выбора модели**

В контексте нашего проекта, где основной задачей является классификация изображений почек на основе КТ снимков, модель VGG16 представляет собой эффективное и мощное решение. Ниже приведены основные аргументы, подтверждающие выбор модели VGG16:

1. Глубокая архитектура: VGG16 является сверточной нейронной сетью с глубокой архитектурой. Она состоит из 16 слоев, включая сверточные, пулинговые и полносвязные слои. Глубокая архитектура позволяет модели извлекать более высокоуровневые и абстрактные признаки из изображений, что способствует более точной классификации заболеваний почек.

2. Превосходная производительность: Модель VGG16 была обучена на больших наборах данных, включая изображения из ImageNet, и достигла высокой точности в задаче классификации изображений. Ее производительность уже была доказана во многих исследованиях и применениях.

3. Перенос обучения: VGG16 может быть эффективно использована с применением метода переноса обучения. Это означает, что мы можем воспользоваться предварительно обученной моделью VGG16 на большом наборе изображений и затем дообучить ее на нашем специфическом наборе данных почек. Это позволяет извлечь высокоуровневые признаки из изображений почек и повысить точность классификации.

4. Широкое применение и поддержка: Модель VGG16 широко используется в сообществе исследователей и разработчиков глубокого обучения. Ее реализация и предобученные веса доступны во многих фреймворках глубокого обучения, таких как TensorFlow и PyTorch. Это обеспечивает удобство в использовании и поддержку для нашего проекта.

Исходя из этих аргументов, выбор модели VGG16 является обоснованным для нашего проекта по классификации изображений почек на

основе КТ снимков. Она обладает глубокой архитектурой, высокой производительностью и возможностью переноса обучения, что позволит нам достичь высокой точности классификации и получить результаты, важные для нашей задачи.

## **2.2 Архитектура модели**

Модель VGG16 (Very Deep Convolutional Networks for Large-Scale Image Recognition) представляет собой сверточную нейронную сеть с глубокой архитектурой, состоящей из 16 слоев. Она была разработана и представлена в 2014 году группой исследователей из Университета Оксфорда.

Основная особенность архитектуры VGG16 — это использование небольших 3x3 сверточных фильтров во всех сверточных слоях, что позволяет получить более глубокое представление изображений и более точно выявлять особенности объектов.

Архитектура VGG16 (рис. 1) состоит из следующих основных слоев:

1. Входной слой: принимает на вход изображение размером 224x224 пикселей.

2. Сверточные слои: состоит из 13 сверточных слоев, каждый из которых следует за слоем активации ReLU. Все сверточные слои имеют фильтры размером 3x3 и выполняют операцию свертки с шагом 1.

3. Пулинговые слои: встроены пулинговые слои после каждых двух последовательных сверточных слоев для уменьшения размерности. Пулинг осуществляется с помощью операции максимального объединения (max pooling) с окном размером 2x2 и шагом 2.

4. Полносвязанные слои: после последних сверточных и пулинговых слоев следуют 3 полносвязанных слоя с 4096 нейронами, каждый из которых использует активацию ReLU. Последний полносвязанный слой выполняет классификацию на выходные классы.

5. Выходной слой: последний полносвязанный слой содержит число нейронов, соответствующее количеству классов в задаче классификации

изображений. Для нашего проекта это будет число, отражающее количество типов заболеваний почек.

Архитектура VGG16 отличается своей простотой и глубиной, что позволяет ей эффективно извлекать высокоуровневые признаки из изображений и обеспечивать высокую точность классификации.




Рис. 1 — Архитектура модели VGG16

### 2.3 Алгоритм применения модели для классификации изображений

Алгоритм применения модели VGG16 для классификации изображений включает следующие шаги:

1. Подготовка данных: сборка и подготовка набора данных КТ снимков почек с различными заболеваниями.
2. Предобработка данных: изменение размера изображений на 224x224 пикселей и выполнение нормализации пикселей.
3. Загрузка и инициализация модели: загрузка предварительно обученной модели VGG16 и инициализация ее весов.
4. Извлечение признаков: прогон каждого изображения через модель VGG16, чтобы получить высокоуровневые признаки.
5. Обучение классификатора: используя извлеченные признаки и метки классов, обучение классификатора на этих признаках.
6. Оценка и тестирование модели: оценка производительности модели на проверочной выборке, вычислив метрики точности, полноты и F1-меры. Затем тестирование модели на тестовой выборке для оценки ее обобщающей способности и точности классификации.

Алгоритм применения модели VGG16 для классификации изображений на основе КТ снимков почек позволяет автоматизировать процесс диагностики и улучшить точность диагноза, что имеет важное практическое значение для области здравоохранения.

### **3. Программная реализация модели**

#### **3.1 Обоснование выбора средств разработки**

При разработке проекта необходимо выбрать эффективные инструменты для обработки и анализа данных, а также для создания и обучения моделей машинного обучения. В рамках данного проекта были выбраны следующие средства разработки: NumPy, Matplotlib, TensorFlow, Keras, scikit-learn и seaborn.

Ниже приведено обоснование выбора каждого из этих инструментов и описание их роли в реализации проекта:

1. NumPy является мощной библиотекой для работы с многомерными массивами данных. Она обеспечивает эффективные вычислительные возможности и функции для научных вычислений, необходимых для обработки и анализа данных в проекте.

2. Matplotlib предоставляет широкие возможности для визуализации данных, включая построение графиков, диаграмм и диагностических изображений. Она позволяет наглядно представить результаты анализа и визуально исследовать данные.

3. TensorFlow — это мощная библиотека машинного обучения и глубокого обучения, которая предоставляет гибкие инструменты для создания и обучения нейронных сетей. Она поддерживает широкий спектр моделей и алгоритмов, а также обеспечивает высокую производительность при обработке больших объемов данных.

4. Keras является высокоуровневым интерфейсом для работы с TensorFlow и другими фреймворками глубокого обучения. Она упрощает создание и обучение моделей нейронных сетей, предоставляя интуитивный и простой в использовании API.

5. Scikit-learn — это библиотека машинного обучения с открытым исходным кодом, которая предоставляет широкий спектр алгоритмов для классификации, регрессии, кластеризации и других задач. Она обеспечивает



простой и единообразный интерфейс для работы с различными моделями машинного обучения.

6. Seaborn — это библиотека визуализации данных, построенная на основе Matplotlib. Она предоставляет более высокоуровневые и стилизованные графики, что делает их более привлекательными и информативными для представления данных.

Выбор этих средств обусловлен их функциональностью, гибкостью, широкой поддержкой сообщества и удобством использования. Они обеспечивают необходимые инструменты для обработки, анализа, визуализации данных и реализации моделей машинного обучения, что делает их подходящими для решения задач в проекте.

### **3.2 Описание программной реализации**

1. Загрузка и предобработка данных: сначала необходимо загрузить набор данных, состоящий из снимков компьютерной томографии почек и соответствующих меток классов (нормальное состояние или наличие определенного заболевания). Далее данные подвергаются предобработке, включающей масштабирование изображений до единого размера, нормализацию значений пикселей.

2. Создание архитектуры модели: для реализации модели глубокого обучения, в данном случае модели VGG-16, необходимо создать архитектуру модели. Это включает определение слоев нейронной сети, их последовательное соединение и конфигурацию параметров каждого слоя, таких как количество фильтров в сверточных слоях, размер окна свертки, функции активации и др.

3. Обучение модели: после создания архитектуры модели следует провести этап обучения. Во время обучения модель подстраивается под данные, путем оптимизации функции потерь с использованием оптимизатора и заданной метрики. Обучение происходит на разделенной на обучающую

выборку, алгоритм автоматически оптимизирует веса модели, чтобы минимизировать ошибку на тренировочных данных.

4. Оценка модели: после завершения обучения необходимо оценить производительность модели. Для этого используется отложенная тестовая выборка, на которой модель еще не видела. Оценка может включать вычисление метрик, таких как точность (accuracy), полнота (recall), точность (precision) и потери (loss). Эти метрики позволяют оценить качество классификации модели и ее способность распознавать заболевания почек.

5. Применение модели: после успешного обучения и оценки модели, ее можно применять для распознавания заболеваний почек на новых изображениях. Для этого загружаются новые снимки компьютерной томографии, проходят через предварительную обработку и затем подаются на вход модели для классификации. Модель выдает предсказание, указывающее на наличие заболевания или нормальное состояние почек на изображении.

## **4. Тестирование модели**

### **4.1 Описание процесса тестирования**

Процесс тестирования модели глубокого обучения для распознавания заболеваний почек включает следующие шаги:

1. Подготовка тестовой выборки: для тестирования модели был подготовлен набор данных, который не использовался в процессе обучения и валидации модели. Тестовая выборка представляет собой репрезентативный набор изображений с различными патологиями почек и нормальными состояниями. Подготовка данных для использования с моделью.

2. Загрузка обученной модели: тестирование проводится с использованием обученной модели, которая была сохранена после процесса обучения.

3. Применение модели на тестовых данных: загрузка тестовых изображений через загруженную модель. Каждое изображение подается на вход модели, и модель делает предсказание относительно наличия заболевания или нормального состояния почек.

4. Оценка производительности модели: сравнение предсказанных значений с истинными метками классов из тестовой выборки.

Весь процесс тестирования модели позволяет оценить ее эффективность и точность в распознавании заболеваний почек на новых изображениях, которые не использовались в процессе обучения. Это важный этап для оценки

и верификации работы модели перед ее применением в реальных условиях.

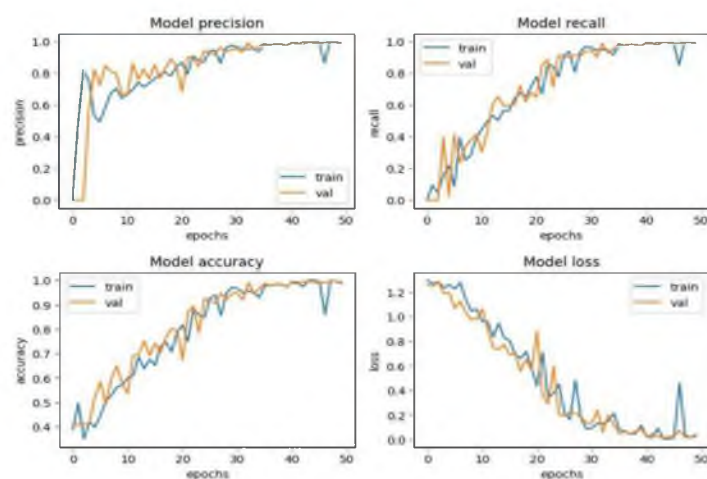


Рис. 2 — Тестирование модели по эпохам




Рис. 3 — Матрица точности

## **Заключение**

В ходе выполнения данной работы была выбрана и реализована модель для распознавания заболеваний почек, которая позволяет автоматизировать процесс установление патологий и может быть использована в различных практико-ориентированных приложениях.

Получены и закреплены навыки работы с моделями: выбор, реализация, обучение, тестирование и возможность применения для решения практических задач.

Кроме этого, отработаны навыки формирования датасета и оценки возможности его использования для обучения моделей.

## Перечень использованных информационных ресурсов

1. Яндекс. Статья «Компьютерная томография. Информация для пациентов» [Электронный ресурс], URL: <https://yandex.ru/health/turbo/articles?id=7665> (дата обращения: 12.05.2023г.)
2. Олимп здоровья. Статья «КТ почек» [Электронный ресурс], URL: [https://olimp03.ru/doc\\_blog/kt-pochek](https://olimp03.ru/doc_blog/kt-pochek) (дата обращения: 12.05.2023г.)
3. Medium. Статья «Компьютерное зрение в медицине» [Электронный ресурс], URL: <https://medium.com/secuteck/компьютерное-зрение-в-медицине-bf94e706592b> (дата обращения: 12.05.2023г.)
4. Хабр. Статья «Что такое свёрточная нейронная сеть» [Электронный ресурс], URL: <https://habr.com/ru/articles/309508/> (дата обращения: 12.05.2023г.)
5. Medium. Статья «Image classification using machine learning-support vector machine (SVM)» [Электронный ресурс], URL: <https://medium.com/analytics-vidhya/image-classification-using-machine-learning-support-vector-machine-svm-dc7a0ec92e01> (дата обращения: 12.05.2023г.)

## Приложение А – Листинг объявления модели

```
model = tf.keras.models.Sequential([

    tf.keras.layers.Conv2D(32,(3,3),strides=(1,1),activation='relu',padding='same',
input_shape=train_dataset.image_shape),
    tf.keras.layers.MaxPooling2D(pool_size=(2,2)),

    tf.keras.layers.Conv2D(64,(3,3),strides=(1, 1) ,padding='same',activation='relu'),
    tf.keras.layers.MaxPooling2D(pool_size=(2,2)),

    tf.keras.layers.Conv2D(128,(3,3),strides=(1, 1),padding='same', activation='relu'),
    tf.keras.layers.MaxPooling2D(pool_size=(2,2)),

    tf.keras.layers.Conv2D(256,(3,3),strides=(1, 1),padding='same', activation='relu'),
    tf.keras.layers.MaxPooling2D(pool_size=(2,2)),

    tf.keras.layers.Flatten(),

    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dense(64, activation='relu'),
    tf.keras.layers.Dense(4, activation='softmax'),

])
```